




Vision Transformer (ViT): 이미지는 16x16 단어의 가치를 가진다

CNN을 넘어, 대규모 스케일의 이미지 인식을 위한 트랜스포머의 도약

Original Paper: An Image is Worth 16x16 Words (ICLR 2021)


Authors: Alexey Dosovitskiy, Lucas Beyer, et al. (Google Research, Brain Team)

Presentation Context: Technical Deep Dive & Legacy Analysis (2021-2025)

컴퓨터 비전의 패러다임 전환: CNN에서 트랜스포머로

NLP의 혁명 (NLP Revolution):


트랜스포머(Transformer)의 등장 이후, BERT와 GPT 같은 대규모 언어 모델이 사실상의 표준(de-facto standard)으로 자리 잡았습니다. 이들은 거대한 텍스트 코퍼스를 통해 사전 학습(Pre-training)하고 미세 조정(Fine-tuning)하는 방식입니다.



Vision의 정체 (Vision Status Quo):

반면 컴퓨터 비전 분야는 여전히 ResNet과 같은 CNN 아키텍처가 지배적이었습니다.

Attention 메커니즘은 CNN과 결합되거나 보조적인 역할에 머물렀습니다.




The Core Question

"CNN의 고유한 구조적
편향(Inductive Bias) 없이,
표준 트랜스포머를 이미지에
직접 적용할 수 있을까?"

"이미지를 텍스트 시퀀스처럼
처리한다면 어떤 결과가 나올까?"

이미지를 텍스트처럼 읽는 법 (Methodology)




Key Concept: Split & Flatten

이미지(x)를 고정된 크기의 패치(x_p)로 분할합니다. 본 논문에서는 **16x16** 크기의 패치를 사용합니다. 이는 NLP에서의 '**단어(Token)**'와 동일하게 취급됩니다.

Technical Detail:

- **Linear Projection (선형 투영):** 각 패치를 1차원 벡터로 평탄화(Flatten)한 뒤, 학습 가능한 선형 레이어를 통과시켜 일정한 차원(D)의 임베딩으로 변환합니다.
- **Position Embeddings:** 트랜스포머는 순서 정보가 없으므로, 패치의 위치 정보를 담은 임베딩을 더해줍니다.

순수 트랜스포머 아키텍처 (Pure Transformer Architecture)



- **Standard Encoder:** BERT에서 사용된 것과 동일한 표준 트랜스포머 인코더(MSA + MLP)를 사용합니다. 구조적 변경을 최소화하여 확장성(Scalability)을 확보했습니다.
- **Learnable [class] Token:** 시퀀스의 맨 앞에 학습 가능한 [class] 토큰을 추가합니다. 인코더의 출력에서 이 토큰의 상태가 이미지 전체의 표현(Representation)으로 사용되어 분류(Classification)를 수행합니다.
- **Hybrid Option:** 패치 대신 CNN의 Feature Map을 입력으로 사용하는 **하이브리드 모델**도 가능합니다.

귀납적 편향(Inductive Bias) 대 대규모 학습(Large Scale Training)

CNN (ResNet)

강한 귀납적 편향 (High Inductive Bias)

- **Locality (지역성):** 픽셀은 주변 픽셀과 연관성이 높다는 가정.
- **Translation Equivariance (평행 이동 등가성):** 사물의 위치가 바뀌어도 동일하게 인식하는 성질.
- **결과:** 적은 데이터로도 효율적인 학습이 가능하지만, 모델의 유연성이 제한될 수 있음.


Transformer (ViT)

적은 귀납적 편향 (Low Inductive Bias)

- 초기화 시점에서는 패치 간의 2차원 위치 관계나 지역적 특징을 전혀 모름.
- 모든 공간적 관계(**Spatial Relations**)를 데이터를 통해 처음부터 학습해야 함.

The Insight: 중소 규모 데이터(ImageNet)에서는 편향이 부족한 ViT가 불리하지만, 대규모 데이터(14M~300M images)에서는 대규모 학습이 귀납적 편향을 압도한다.

데이터 규모에 따른 성능 변화 (Performance Scaling)



Key Takeaway: 데이터셋의 크기가 커질수록 ViT의 성능은 계속 향상되는 반면, ResNet은 성능이 포화(Saturate)되는 경향을 보입니다. JFT-300M 사전 학습 시 ViT는 SOTA를 달성합니다.

압도적인 효율성과 SOTA 달성 (State-of-the-Art)

ViT-H/14 (JFT-300M Pre-trained) Results

ImageNet
Top-1 Accuracy


88.55%
vs Noisy Student 88.4%

CIFAR-100 Accuracy

94.55%

Efficiency Comparison (Training Cost)

ResNet (BiT-L)



ViT-L/16




Higher Performance

ViT는 동일 성능을 내기 위해 **2~4배 더 적은 컴퓨팅 자원(TPUv3-core-days)**을 사용합니다.

Conclusion: ViT는 성능과 학습 효율성(Performance/Compute Trade-off) 두 마리 토끼를 모두 잡았습니다.

모델 내부 분석 1: 임베딩이 학습한 것

Linear Projection Filters



초기 패치 임베딩 필터는 CNN의 초기 레이어와 유사한 **기저 함수(Basis Functions)**를 학습하여 선, 질감 등 저수준 구조를 파악합니다.


Position Embeddings



패치 간의 위치 유사도를 시각화한 결과, 모델은 명시적인 정보 없이도 **행(Row)과 열(Column) 구조 및 거리 개념을 스스로 학습**하여 복원해냈습니다.

모델 내부 분석 2: 전역적 정보 통합 (Global Attention)

Insight: CNN은 층이 깊어져야만 시야(Receptive Field)가 넓어지지만, ViT는 가장 낮은 레이어의 일부 헤드에서도 이미 이미지 전체를 참조합니다. 이는 전역적 문맥을 처음부터 고려한다는 것을 의미합니다.



모델은 무엇을 보는가? (Visualizing Attention)

Original Input




Attention Rollout



Output Token에서 Input Space로의 어텐션을 시각화(Attention Rollout)했습니다. 모델은 이미지 내의 **의미 있는 영역(Semantically Relevant Regions)**—강아지의 형태—에 정확히 집중하고 있습니다. 이는 사전 학습된 ViT가 객체를 효과적으로 분할하고 인식하고 있음을 보여줍니다.

자기 지도 학습의 가능성 (Self-Supervision)



Method:

NLP의 BERT처럼 이미지 패치의 일부를
마스킹(Masking)하고 이를 복원하는

Masked Patch Prediction을
실험했습니다.

Result:

처음부터 학습(Scratch)하는 것보다 높은
성능(ImageNet 79.9%)을 보였습니다.
지도 학습(Supervised)보다는 아직 낮지만,
라벨 없는 대량의 데이터를 활용할 수 있는
잠재력을 확인했습니다.


ViT의 유산과 진화 (Legacy & Evolution to 2025)

2021 (This Paper)

2025 (New Perspective)


Vision Transformer (ViT)

이미지를 패치 시퀀스로 처리하는 개념 정립.



Video-LLMs (NeurIPS 2025)

Enhancing Temporal Understanding in Video-LLMs



Current Application: 최신 Video-LLM 연구에서는 ViT 인코더 내부에 **시간적 어텐션(Stacked Temporal Attention)**을 통합하여 비디오의 시간적 흐름을 이해합니다. ViT는 단순한 이미지 분류기를 넘어, **멀티모달 및 비디오 이해(Video Understanding)**를 위한 **핵심 비전 인코더**로 자리 잡았습니다.

결론: 단순함이 확장성을 만날 때

■ Direct Application

이미지 특화 구조 없이 표준 트랜스포머를 그대로 적용했습니다.

■ Scale is Key

귀납적 편향의 부재는 대규모 데이터와 컴퓨팅 파워로 극복 가능하며, 오히려 더 높은 성능 상한선을 제공합니다.

■ Efficiency

CNN보다 더 적은 비용으로 더 높은 성능을 달성했습니다.

“ViT는 컴퓨터 비전의 새로운 표준(Standard)이 되었으며, 정지 영상을 넘어 비디오와 멀티모달 인공지능의 기반이 되고 있습니다.”